TECHNICKÁ UNIVERZITA V LIBERCI
Fakulta mechatroniky, informatiky
a mezioborových studií

Vyhledávání

a deep learning

František Kynych
3. 10. 2024 | MVD

TECHNICKÁ UNIVERZITA V LIBERCI
Fakulta mechatroniky, informatiky
a mezioborových studií

Část I.:
Úvod do vyhledávání, základní metody

Co je to vyhledávač?

- Program používaný k získávání informací
  - Získává data -> poskytuje užitečné informace
- Dělíme na:
  - Obecné vyhledávání – Google, DuckDuckGo, Bing, Baidu, …
  - Vertikální vyhledávání
    - Zaměřují se pouze na určitou oblast – Google Scholar
- Základní úlohy vyhledávače
  - Indexování
    - Efektivní příjem a ukládání dat
  - Dotazování
    - Poskytování funkci vyhledávání
  - Hodnocení
    - Správné hodnocení výsledků pro návrat relevantních výsledků

Základní prvky textové analýzy

- Tokenizér
  - Rozdělí proud textu na slova, fráze nebo jiné prvky (tokeny)
- Token filter
  - Přijímá proud tokenů, které modifikuje, maže, nebo přidává další
- Základní zpracování textu „Mám rád vyhledávače“

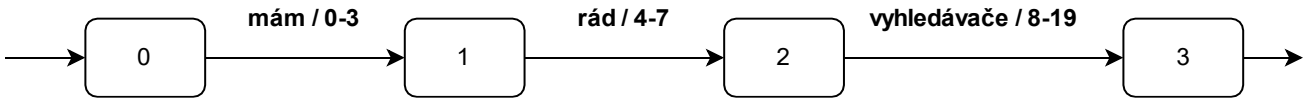

  - Dělení na slova pomocí mezer, lower case, držení pozice
    - V praxi komplexnější analyzéry – stopword list, stemming, …

Indexování

- Dokument
  - Kniha, článek, webová stránka, …
- Proces zpracování dokumentů a uložení jednotlivých slov (tokenů) s odkazy na cílový dokument
  - Invertovaný soubor (index)

Slovo	Doc id
metoda	1
vytěžování	1, 2
data	1
neuron	3
vyhledávání	1, 2, 3

Vyhledávání

- Na počátku se podporovalo pouze vyhledávání klíčových slov
- Query parser
  - Zodpovědný za správné parsování dotazu
  - Vyhledávání „latest research in artificial intelligence“
    - Měl by poznat, že artificial intelligence je jedna fráze
    - Měl by dokázat převést slovo latest na časové omezení dotazu (např. stáří < 3 měsíce)

- Textová analýza
  - Pipeline podobná jako u indexování (rozdělení slov, lower case, stemming)

- Navrácení výsledků
  - Invertovaný index -> navrácení **všech** výsledků s danými slovy neseřazeně

Hodnocení relevance (ranking)

- Nejdůležitější část vyhledávače
  - Prvních 10 výsledků by mělo být nejvíce relevantních
  - Uživatel nemusí procházet všechny dokumenty – menší zátěž systému

- Retrieval model
  - Zodpovědný za ohodnocení všech výsledků vyhledávání
  - Každý dokument obdrží skóre -> seřazení výsledků

- Jak vybrat správný model?
  - Velké množství metod pro hodnocení
  - Často se relevance dokumentu mění s časem
    - Potřeba průběžně přizpůsobovat

Model vektorového prostoru

- Označujeme jako **VSM** (Vector Space Model)
- Dokumenty i dotazy jsou reprezentovány pomocí vektorů
- Základní princip:

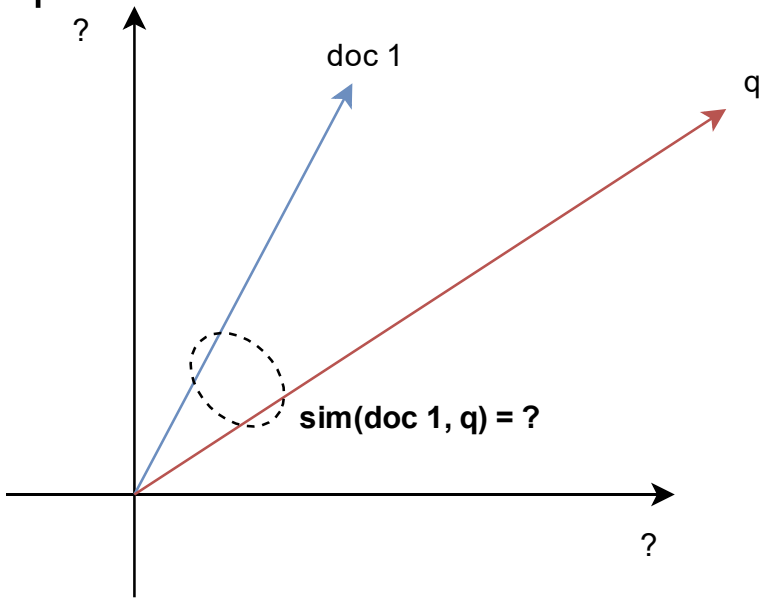

VSM – bag-of-words implementace

- Bag-of-words
  - „Metody vytěžování dat“ -> [“Metody”, “vytěžování”, “dat”]
  - BoW = {“Metody”: 1, “vytěžování”: 1, “dat”: 1}
- Pro zjednodušení pouze binární přístup a relevance pomocí skalárního součinu

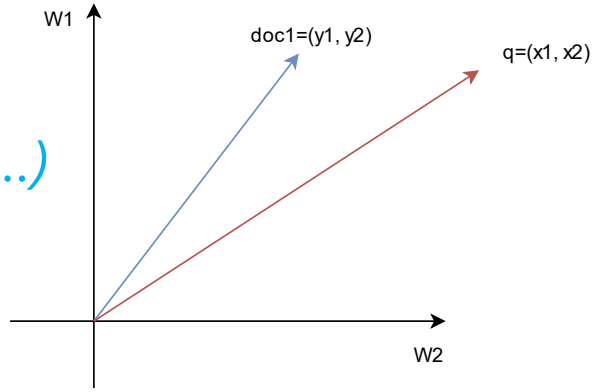

- Máme $q=(x_1, x_2, x_3, \ldots)$ a $doc1=(y_1, y_2, y_3, \ldots)$
- Slova $x_i, yi \in \{0, 1\}$
  - 0: slovo není v textu
  - 1: slovo je v textu
- $sim(q, doc1) = x_1y_1 + x_2y_2 + x_3y_3 + \ldots = \sum_{i=1}^{N} x_iy_i$
- Dimenze vektoru = N (velikost slovníku)

VSM – bag-of-words příklad

q = „Metody vytěžování dat“

doc1 = „… využité metody …“

doc2 = „… metody vytěžování dat …“

Slovník V = {využité, metody, vytěžování, dat}

q = (0, 1, 1, 1)

doc1 = (1, 1, 0, 0)

doc2 = (0, 1, 1, 1)

sim(q, doc1) = 0×1 + 1×1 + 1×0 + 1×0 = 1

sim(q, doc2) = 0 + 1 + 1 + 1 = 3

TF-IDF

- V praxi potřebujeme použít počet výskytů
- TF = term frequency
  - Kolikrát se výraz vyskytuje v dokumentu
- Problém s TF
  - Pokud se slovo vyskytuje často v každém dokumentu (spojky, předložky, …)
- IDF = inverse document frequency
  - V jaké míře se slovo vyskytuje v celé kolekci
  - Využito k penalizaci častých slov

TF-IDF

$$x_i = c(W_i, q) \quad (počet\ slov\ W_i\ v\ dotazu\ q)$$
$$y_i = c(W_i, d) \times IDF(W_i)$$
$$IDF(W) = \log(\frac{M+1}{k})$$

M = celkový počet dokumentů v kolekci

k = celkový počet dokumentů obsahující slovo W

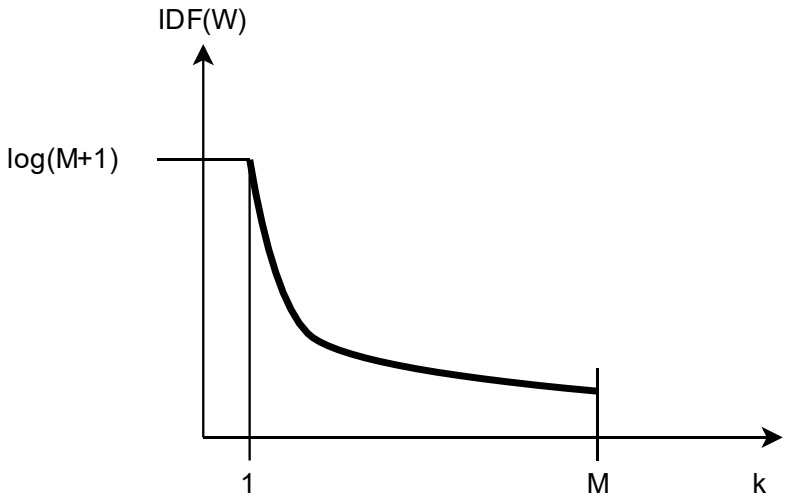

TF-IDF

- Výsledná rovnice při použití TF-IDF a počítání relevance pomocí skalárního součinu:

$$sim(q,d) = \sum_{i=1}^{N} x_i y_i = \sum_{w \in q \cap d} c(w,q)c(w,d)\log\left(\frac{M+1}{df(w)}\right)$$

M = celkový počet dokumentů v kolekci

df(w) = celkový počet dokumentů obsahující slovo w (document frequency)

Okapi BM25

- Úprava TF-IDF pomocí TF transformace (TF(w, d))
- Problém TF-IDF
  - Jedno časté slovo z dotazu může dominovat nad ostatními
    - Např. často v nějakém nerelevantním dokumentu, ale méně často v celé kolekci
- Parametr $k \geq 0$
  - k = 0: binární TF
  - Příliš velké k: y=x (TF)

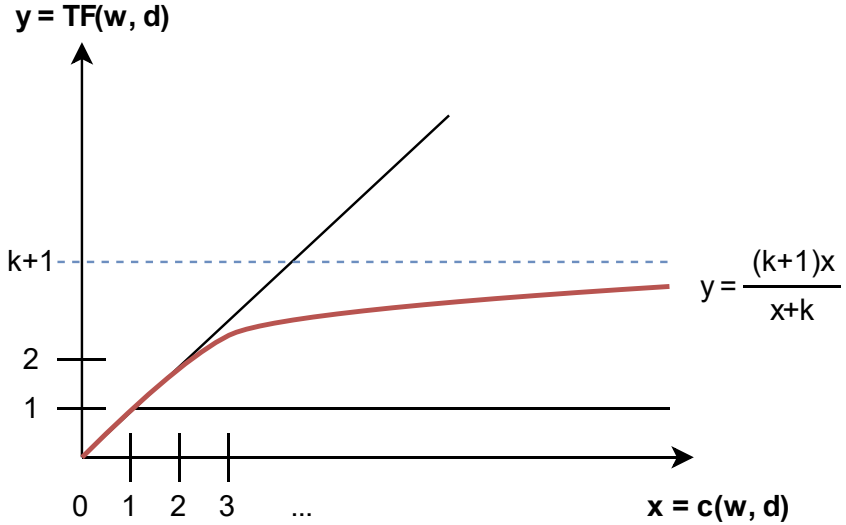

Okapi BM25

- Výsledná rovnice při použití TF transformace a počítání relevance pomocí skalárního součinu:

$$sim(q,d) = \sum_{i=1}^{N} x_i y_i = \sum_{w \in q \cap d} c(w,q) \frac{(k+1)c(w,d)}{c(w,d)+k} log(\frac{M+1}{df(w)})$$

- Kromě TF transformace se používá normalizace délky dokumentu
  - Dlouhý dokument bude mít větší šanci vyhledání uživatelskými dotazy

Okapi BM25

- Penalizace s pomocí parametru $b \in [0, 1]$

$$norm = 1 - b + b\frac{|d|}{avdl}$$

$|d|$ = délka dokumentu

$avdl$ = průměrná délka dokumentu

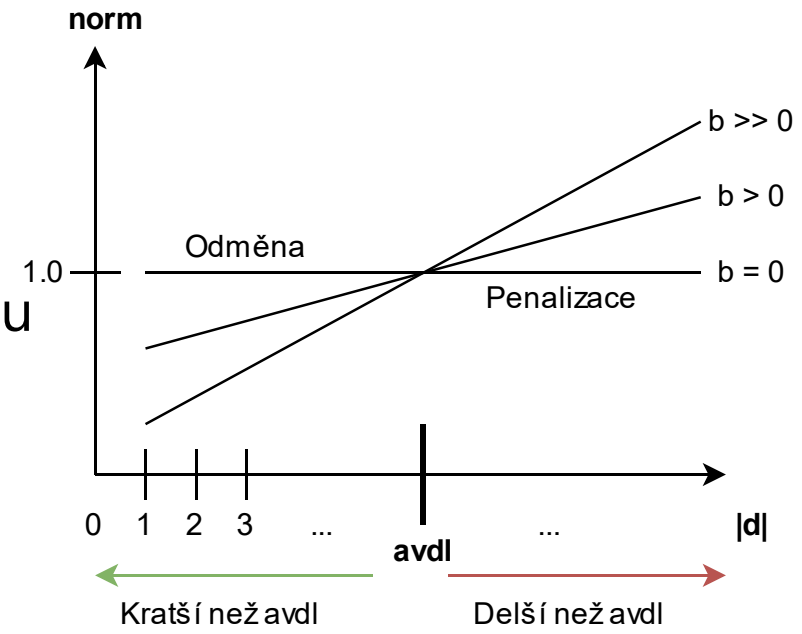

Okapi BM25

- Výsledná rovnice BM25 při počítání relevance pomocí skalárního součinu:

$$sim(q,d) = \sum_{i=1}^{N} x_i y_i = \sum_{w \in q \cap d} c(w,q) \frac{(k+1)c(w,d)}{c(w,d) + k(1 - b + b\frac{|d|}{avdl})} log(\frac{M+1}{df(w)})$$

- V praxi se používá rozšířený BM25
  - BM25F pro strukturované dokumenty (F = fields)
  - BM25+ zabraňuje příliš velké penalizaci dlouhých dokumentů

- BM25 používá defaultně Elasticsearch

Limitace předchozích metod

- Bag-of-words
  - Rozdělení textu na jednotlivá slova
    - Nezáleží na pořadí slov v dotazu
- Fungují hůře při vyhledávání nad delšími dokumenty
- Problém při špatném definování dotazu
  - Nelze nalézt synonyma

- Pokud není potřeba řešit některý ze zmíněných problémů, tak je BM25(F/+) dostačující
  - Jinak se používá jako baseline

Část III.:
Vyhodnocení vyhledávání

Vyhodnocení vyhledávání

- Pro obecné vyhodnocení se používají datasety z Text Retrieval Conference (NIST TREC)

- Při použití Apache Lucene lze vyhodnocení vytvořit pomocí Lucene4IR nástroje
  - Vyhodnocuje nad CACM datasetem (názvy a abstrakty článků)
  - Obsahuje nástroj k vyhodnocení nad TREC datasetem

Co vyhodnocovat?

- Efektivnost / přesnost
  - Měříme schopnost vyhledávání relevantních dokumentů
- Výkonnost
  - Jak dlouho trvá získání výsledků?
  - Jak moc je systém zatížený?
- Použitelnost
  - Je vytvořený systém vhodný pro danou aplikaci?

Precision + Recall

- Precision
  - Podíl navrácených výsledků, které jsou relevantní
- Recall
  - Podíl relevantních dokumentů, které jsou navráceny

Dokument	Navrácený	Nenavrácený
Relevantní	a	b
Nerelevantní	c	d

$$Precision = \frac{a}{a + c}$$

$$Recall = \frac{a}{a + b}$$

- Ideální stav -> Recall = Precision = 1
- Často definován cutoff (např. precision @ 10 docs)

F-Measure

- Kombinace Precision (P) a Recall (R)
- Parametr β, většinou hodnota 1
  - Ovládá jaký důraz je kladen na Precision nebo Recall

$$F_\beta = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

$$F1 = \frac{2PR}{P + R}$$

Precision Recall křivka

- Např. máme 10 relevantních dokumentů (+ relevatní, - nerelevantní)

Dokumenty	Precision	Recall
D1 +	1/1	1/10
D2 +	2/2	2/10
D3 -	2/3	2/10
D4 -	2/4	2/10
D5 +	3/5	3/10
D6 -	…	…
D7 -	…	…
D8 +	4/8	4/10
?	?	10/10

- Z těchto bodů vytvoříme křivku

Precision Recall křivka

- Máme dva systémy A a B, který je lepší?

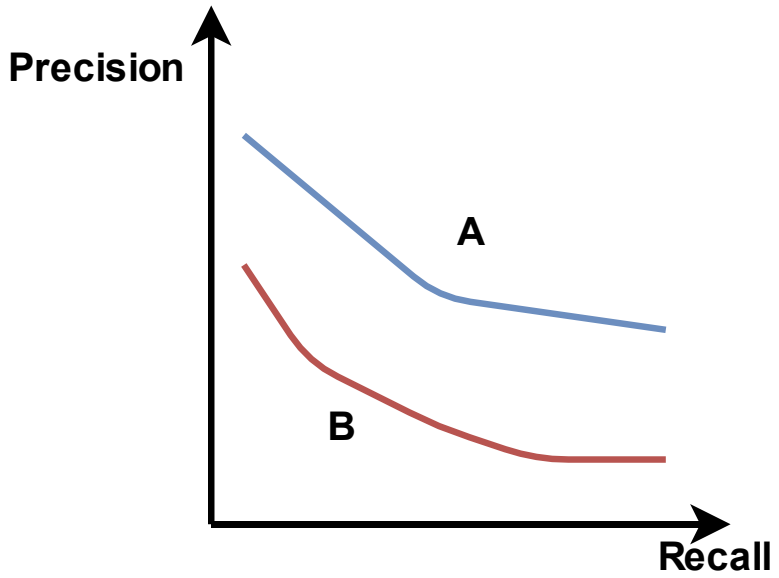

Precision Recall křivka

- Máme dva systémy A a B, který je lepší?

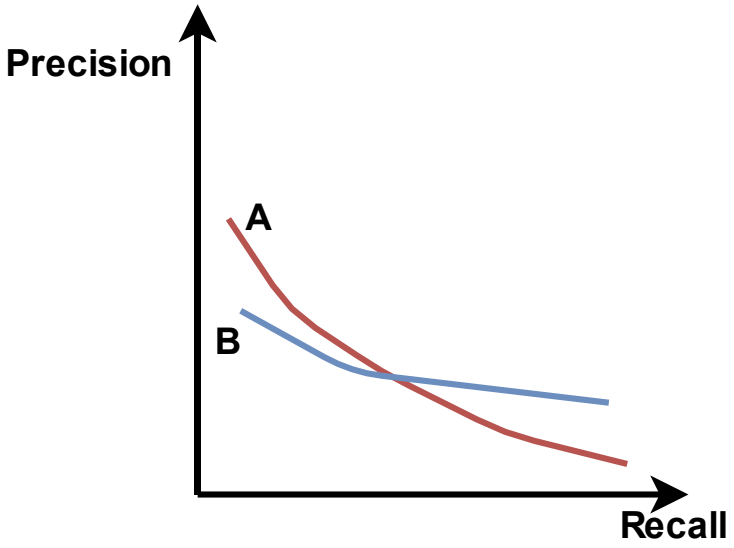

Precision Recall křivka

- Máme dva systémy A a B, který je lepší?

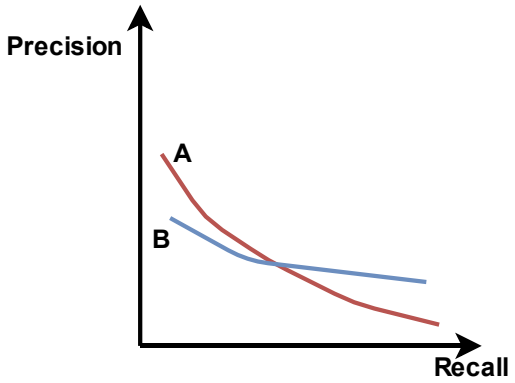

- Záleží na aplikaci
  - Uživatel chce mít při vyhledávání prvních pár výsledků nejrelevantnějších -> systém A
    - Např. chci zjistit, co se dnes děje
  - Někdo chce naopak projít co nejvíce výsledků -> systém B
    - Např. chci zjistit, zda můj nápad už někdo realizoval dříve

Normalized Discounted Cumulative Gain (NDCG)

- Vyhodnocení pro různé úrovně relevance (1 = nerelevantní, 2 = částečně relevantní, 3 = relevantní)

Doc	Gain	Cumulative gain	Discounted Cumulative Gain
D1	3	3	3
D2	**2**	3+**2**	$3 + \frac{2}{\log 2}$
D3	**1**	3+2+**1**	$3 + \frac{2}{\log 2} + \frac{1}{\log 3}$
D4	1	3+2+1+1	…
D5	3	3+2+1+1+3	…

$$NDCG = \frac{DCG@5}{IdealDCG@5}$$

$$DCG@5 = 3 + \frac{2}{\log 2} + \ldots + \frac{3}{\log 5}$$

$$IdealDCG@5 = 3 + \frac{3}{\log 2} + \frac{3}{\log 3} + \frac{3}{\log 4} + \frac{2}{\log 5}$$

Užitečná literatura / kurzy

- TEOFILI, Tommaso. *Deep learning for search*. Shelter Island: Manning, [2019]. ISBN 978-161-7294-792.
- Coursera kurz Text Retrieval and Search Engines